

“MODELO DE APRENDIZAJE AUTOMÁTICO PARA LA DETECCIÓN TEMPRANA DE ANEMIA INFANTIL EN EL PERÚ”

Autor/Autores: Adrianna López, Martin Vásquez, Kevin Vega y Alvaro Ferro.

Resumen - La anemia infantil es una deficiencia nutricional crítica para el desarrollo físico y cognitivo, cuya alta prevalencia es un desafío constante en el Perú. Su mitigación requiere análisis avanzados para la planificación preventiva en salud pública. Se evaluaron modelos de machine learning (Regresión Logística, KNN, Árboles de Clasificación, Random Forest y XGBoost) para predecir este riesgo de forma no invasiva. Con datos sociodemográficos, habitacionales y antropométricos de la ENDES 2023, XGBoost logró la mayor exactitud global (Accuracy = 0.6730). Sin embargo, la Regresión Logística optimizó la sensibilidad clínica (Recall = 0.6429; AUC = 0.7092), resultando el modelo ideal para tamizaje al minimizar falsos negativos. El balanceo con SMOTE y la exclusión de la hemoglobina garantizaron la robustez metodológica.

1. Introducción

La anemia es una de las deficiencias nutricionales más críticas a nivel mundial, y en el Perú representa un problema prioritario de salud pública, afectando significativamente a la población infantil. Su alta prevalencia no solo impacta la salud clínica de los niños, sino que compromete seriamente su desarrollo cognitivo, motor y su futuro bienestar socioeconómico. Tradicionalmente, el diagnóstico de la anemia depende de pruebas de sangre (medición de hemoglobina), lo cual es un enfoque reactivo.

En este contexto, surge la necesidad de aplicar herramientas de Inteligencia Artificial para abordar el problema desde una perspectiva preventiva. Los enfoques estadísticos tradicionales suelen tener limitaciones para capturar las relaciones complejas que existen entre los diversos factores de riesgo (como el nivel socioeconómico, el acceso a servicios básicos y las medidas antropométricas). Por ello, el uso de algoritmos de Machine Learning, específicamente los modelos de clasificación (Regresión Logística, Árboles de Decisión, K-Nearest Neighbors, Random Forest y XGBoost), resulta ideal para encontrar patrones ocultos en los datos y predecir el riesgo de anemia antes de realizar pruebas invasivas.

La pregunta de investigación que guía este trabajo se centra en determinar:

- ¿Es posible predecir con un nivel de precisión aceptable el riesgo de padecer anemia en niños peruanos de 6 a 59 meses

utilizando factores socioeconómicos, demográficos y de condiciones de vivienda mediante algoritmos de Machine Learning?

En respuesta a esto, se hipotetiza que:

- La aplicación de algoritmos de clasificación de aprendizaje automático sobre los datos demográficos y de salud de la encuesta ENDES 2023 permitirá desarrollar un modelo capaz de identificar tempranamente a los niños con alto riesgo de anemia, demostrando que factores como el índice de riqueza, la educación y las condiciones sanitarias tienen un alto poder predictivo.

Para responder esta interrogante, el objetivo general consiste en:

- Desarrollar y evaluar un modelo de aprendizaje automático de clasificación para la detección temprana del riesgo de anemia en niños peruanos, utilizando la base de datos de la ENDES 2023.

Los objetivos específicos incluyen:

- Preprocesar y estandarizar el conjunto de datos integrado por los módulos de vivienda, hogar y salud del INEI para prepararlo para el modelado.
- Implementar y comparar el rendimiento de diferentes algoritmos de clasificación (Regresión Logística, Árboles de Clasificación, KNN, Random Forest y XGBoost).
- Identificar cuáles son los factores socioeconómicos y demográficos que tienen mayor peso en la predicción de la enfermedad.



2. Trabajos relacionados

Prediction of Anemia using Machine Learning Algorithms

En su investigación centrada en niños menores de cinco años en Nepal, Dhakal et al. (2023) abordaron la predicción de la anemia basándose exclusivamente en datos clínicos , procesando 700 registros médicos de hemogramas completos. Tras evaluar diversos algoritmos, se determinó que el modelo Random Forest obtuvo el mejor desempeño predictivo con una precisión del 98.4%. Lo importante aquí es que usaron variables clínicas directas: niveles de hemoglobina, conteo de glóbulos rojos, hematocrito y volumen corpuscular medio (MCV). Es ideal si tenemos acceso a resultados de laboratorio.

Machine learning algorithms to predict the childhood anemia in Bangladesh

Por otro lado, Khan et al. (2019) evaluaron la eficacia de múltiples algoritmos para predecir la anemia infantil utilizando datos de encuestas nacionales demográficas y de salud en Bangladesh. Se demostró que el modelo Random Forest logró una precisión del 68.53%. Las variables utilizadas fueron: el nivel de riqueza del hogar, la educación y estado de anemia de la madre, además de datos críticos de salud del niño como la edad en meses, la presencia reciente de fiebre o diarrea, el estado nutricional según su talla y peso. Este enfoque evidencia que para predecir la anemia no basta con datos sociales, sino que es vital integrar el entorno de salud y la condición biológica de la madre.

Predicting Childhood Anaemia in Nigeria: A Machine Learning Approach to Uncover Key Risk Factors

Finalmente, un estudio reciente en Nigeria realizado por Ja'afar y Uthman (2025) analizó los datos de más de 13,000 niños para medir con precisión esta enfermedad. El algoritmo Extra Trees demostró el mayor rendimiento predictivo con 75.65% de precisión. El mayor aporte de este estudio es que destaca variables clave tanto familiares: cantidad de hijos en el hogar, orden de nacimiento y sexo del niño. Además de variables innovadoras: acceso a medios de comunicación, distancia a fuentes de agua, dificultades económicas a la salud y temperatura del suelo. Demostrando que las variables de entorno y geográficas también influyen en la anemia.

Tabla 1
Cuadro Comparativo de investigaciones referenciadas

Países Investigados	Autor - Año	Algoritmo mejor desempeño	Variables Relevantes
Anemia en Nepal	Dhakal et al. (2023)	Random Forest con precisión: 98.4%.	Nivel hemoglobina, glóbulos rojos, volumen corpuscular.
Anemia en Bangladesh	Khan et al. (2019)	Random Forest con precisión: 68.53%	Edad, peso y talla del niño; y nivel de riqueza y educativo del hogar.
Anemia en Nigeria	Ja'afar y Uthman (2025)	Extra Trees con precisión: 75.65%	Sexo del niño, distancia a fuentes de agua, ubicación geográfica y condiciones del suelo.

En conclusión, estos estudios demuestran la superioridad de los modelos de clasificación frente a los enfoques tradicionales. Para una investigación basada en encuestas demográficas (prescindiendo de datos clínicos para evitar la fuga de datos), la literatura establece un baseline de exactitud (Accuracy) esperado entre el 68.53% (Khan et al., 2019) y el 75.65% (Ja'afar y Uthman, 2025). Tomando esto como referencia, este trabajo evalúa cinco algoritmos: Regresión Logística, K-NN y Árboles de Decisión (como modelos base e interpretables requeridos en el alcance del curso), junto con Random Forest y XGBoost (arquitecturas avanzadas de ensamble recomendadas por el estado del arte), contrastando empíricamente cuál se adapta mejor al contexto de la infancia peruana.

3. Metodología

■ Enfoque(s) propuesto:

Formalmente, sea **X** el conjunto de variables sociodemográficas, antropométricas y de vivienda de un infante, e **Y** su diagnóstico de anemia. El problema de clasificación consiste en encontrar una función **f: X → Y** que aproxime óptimamente esta relación. Para ello, se evaluarán cinco algoritmos predictivos con el fin de identificar patrones de riesgo recurrentes a partir de datos estrictamente no clínicos.

Recopilación de los Datasets

Los datos fueron obtenidos a partir de la Encuesta Demográfica y de Salud Familiar (ENDES) 2023, elaborada por el Instituto Nacional de Estadística e Informática (INEI). Con el fin de estructurar un conjunto de datos óptimo para la predicción de la anemia, se procedió a consolidar tres módulos de la encuesta: "Características de la Vivienda", "Características del Hogar", "Peso-Talla y Anemia". Durante este proceso de integración, se realizó una rigurosa selección de variables en la que se descartaron varias columnas cuyos datos se alejaban del propósito de la investigación, garantizando así un dataset multidimensional y estrictamente enfocado.

Tabla 2

Variables consolidadas del conjunto de datos.

#	Variable	#	Variable
1	Edad del niño (meses)	10	Nivel educativo del jefe de hogar
2	Peso del niño (kg)	11	Índice de riqueza
3	Talla del niño (cm)	12	Fuente de agua
4	Día de nacimiento	13	Tipo de baño
5	Z-Score Talla/Edad	14	Material predominante del piso
6	Z-Score Peso/Edad	15	Material predominante de paredes
7	Z-Score Peso/Talla	16	Región natural
8	Z-Score IMC	17	Diagnóstico de Anemia (Y)
9	Sexo del jefe de hogar		

Con esta información y basándonos en el estado del arte, los cinco modelos implementados para clasificar el riesgo de anemia son: Regresión Logística, Árboles de Clasificación (Decision Trees), K-Nearest Neighbors (K-NN), Random Forest y XGBoost.

Entrada (X):

Los modelos reciben como entrada un conjunto reducido de variables esenciales para la predicción de la vulnerabilidad infantil, las cuales se han agrupado estratégicamente según su naturaleza:

Variables antropométricas y de salud:

- Edad en meses, peso, talla, día de nacimiento y los indicadores nutricionales estandarizados (Z-Score Talla/Edad, Peso/Edad, Peso/Talla, IMC).

Variables sociodemográficas:

- Sexo y nivel educativo del jefe de hogar, índice de riqueza y región natural.

Variables de condiciones de vivienda:

- Fuente de agua, tipo de baño y material predominante del piso y paredes.

Salida (Y):

La variable objetivo es el "Diagnóstico de Anemia", procesada como una variable binaria discreta donde **1** representa la presencia de la enfermedad ("Con Anemia") y **0** representa un estado de salud normal ("Sin Anemia").

Preprocesamiento y estructuración de Datos

El proceso de preparación de datos fue diseñado para consolidar las respuestas en bruto de las encuestas y transformarlas en una matriz numérica óptima para el entrenamiento de los modelos de clasificación. El flujo de trabajo consistió en los siguientes pasos clave:

- **Integración y Mapeo de Datos:** El primer paso consistió en vincular los registros individuales de los tres módulos distintos de la ENDES 2023 (Características de la Vivienda, Características del Hogar y Peso-Talla/Anemia) utilizando los identificadores únicos de cada encuestado. Una vez unificados, se realizó un filtrado para descartar aquellas columnas que contenían información alejada del objetivo del estudio. Con este conjunto de datos optimizado, se realizó un mapeo para reemplazar los códigos numéricos de las variables categóricas (como el tipo de fuente de agua o material de vivienda) por sus respectivas etiquetas descriptivas en texto, facilitando así la interpretabilidad.
- **Limpieza y Tratamiento de Valores Faltantes:** Se realizó una rigurosa depuración del conjunto de datos. Se eliminaron los registros que presentaban valores nulos o inconsistentes en variables críticas, particularmente en las medidas antropométricas (Z-Scores) y en los resultados del test de hemoglobina. Esta validación fue fundamental para garantizar

que el modelo aprenda de perfiles de salud completos y precisos.

- **Transformación y Escalamiento de Características (Feature Engineering):** Para que los algoritmos puedan procesar la información, las variables categóricas (como índice de riqueza o región) se transformarán mediante la técnica de One-Hot Encoding, convirtiéndolas en vectores binarios. Asimismo, dado que modelos como K-NN y Regresión Logística son muy sensibles a la magnitud de los datos, las variables numéricas continuas (como la edad en meses y los Z-Scores) serán estandarizadas (StandardScaler) para que compartan una misma escala.
- **Definición de la Variable Objetivo (Y) y Prevención de Fuga de Datos:** La variable a predecir se estructuró en un formato binario estándar para clasificación: clase **1** ("Con Anemia") y clase **0** ("Sin Anemia"). En este paso es crucial la eliminación definitiva de la variable "Hemoglobina" del conjunto de características de entrada (X). Esta exclusión previene el sobreajuste por fuga de datos, obligando a los modelos a predecir la enfermedad basados puramente en los factores de riesgo socioeconómicos y antropométricos.

El dataset final quedará estructurado con una matriz de entrada (X) codificada y un vector objetivo (Y) binario. Para la fase experimental, el conjunto de datos se dividirá siguiendo la estrategia Train-Test Split, aislando un 30% de los datos como conjunto de prueba (test set) para la evaluación definitiva. El 70% restante se destinará al bloque de desarrollo, sobre el cual se aplicará un esquema de Validación Cruzada Estratificada de 10 particiones (10-Fold CV) acoplado a una búsqueda en grilla (GridSearchCV). Esta aproximación iterativa permite optimizar los hiperparámetros de los algoritmos utilizando dinámicamente el total de la data de desarrollo para entrenamiento y validación interna, mitigando el riesgo de sobreajuste antes del dictamen final.

Modelos y entrenamiento

Para este trabajo se desarrollarán y adaptarán cinco algoritmos al contexto de salud pública:

- **Regresión Logística:** Se utilizó como modelo inicial de referencia por su transparencia en la interpretación de coeficientes, lo que permite identificar directamente si factores como la falta de agua potable aumentan las probabilidades de enfermedad. Se adaptó utilizando un umbral de decisión probabilístico de 0.5 sobre la función sigmoide.

- **Árboles de Clasificación (Decision Trees):** Modelo altamente valioso en el sector salud por su interpretabilidad jerárquica. El algoritmo particiona los datos evaluando reglas lógicas sobre las variables (ej. ¿El Z-Score de Peso/Edad indica desnutrición?). Su crecimiento fue controlado para evitar el sobreajuste sobre los datos de la ENDES.
- **K-Nearest Neighbors (K-NN):** Método espacial basado en distancias. Se adaptó bajo la premisa de que infantes con perfiles sociodemográficos y antropométricos similares comparten riesgos de salud análogos, diagnosticando a nuevos pacientes mediante la búsqueda de los k casos más parecidos usando la distancia euclidiana.
- **Random Forest:** Arquitectura de ensamble por agregación (Bagging) basada en múltiples árboles de decisión entrenados sobre subconjuntos aleatorios. Al promediar predicciones independientes, reduce drásticamente el sobreajuste y logra capturar relaciones no lineales sin depender de una única estructura jerárquica.
- **XGBoost:** Aplica una estrategia de Boosting secuencial construyendo árboles iterativamente, donde cada nuevo estimador corrige los errores del anterior mediante gradiente descendente. Esta arquitectura maximiza la capacidad para capturar patrones complejos entre los factores de riesgo de anemia infantil en el contexto peruano.

La comparación entre estos modelos permite evaluar distintos enfoques de predicción (probabilístico, jerárquico y por similitud), y determinar cuál se ajusta mejor a la naturaleza de los datos demográficos y de salud. Como resultado esperado en la salida, tenemos una predicción precisa de la vulnerabilidad a la anemia a nivel infantil, lo cual proporciona una herramienta basada en datos para la planificación y focalización de programas de salud pública preventivos.

4. Experimentación y Resultados

- **Setup experimental:**

El entorno empírico del presente estudio se diseñó con la finalidad de caracterizar, optimizar y contrastar la capacidad predictiva de múltiples arquitecturas de aprendizaje automático orientadas a la identificación oportuna del riesgo de anemia infantil a nivel nacional.

Ejecución del Preprocesamiento

El marco de datos analizado proviene del consolidado de microdatos de la Encuesta Demográfica y de Salud Familiar (ENDES 2023). Con el fin de asegurar el rigor metodológico y mitigar la fuga de datos (data leakage), se implementaron las siguientes etapas secuenciales e independientes antes de la fase de entrenamiento:

- **Tratamiento de Multicolinealidad:** Se descartó la variable `Z_SCORE_IMC` al presentar una correlación lineal perfecta (0.99) con `Z_SCORE_PESO_TALLA`, conservando este último por ser el estándar canónico de la OMS.
- **Imputación y Escalamiento Seguro:** Los estimadores `SimpleImputer` y `StandardScaler` se ajustaron exclusivamente en el conjunto de entrenamiento (70%). El conjunto de prueba (30%) fue transformado posteriormente, garantizando el aislamiento de las muestras y evitando la fuga de datos.
- **Mitigación del Desbalance:** Debido a la asimetría estructural de las clases, se aplicó sobremuestreo sintético (SMOTE) únicamente sobre los datos de entrenamiento (equilibrando a 7238 registros por etiqueta). El conjunto de prueba preservó intacta la distribución poblacional original.

Estrategia de Validación y Búsqueda en Grilla

Para evaluar la influencia de los parámetros y la estabilidad de los algoritmos frente a perturbaciones de los datos, se implementó una búsqueda exhaustiva en grilla (`GridSearchCV`) acoplada de manera sincrónica a una Validación Cruzada Estratificada de 10 particiones (10-Fold CV), gobernada por una semilla fija (`seed=7`). El pool experimental integró los cinco enfoques algorítmicos contemplados en la investigación bajo las siguientes grillas de exploración:

- **Regresión Logística (LogReg):** Clasificador base lineal probabilístico. Se evaluó el inverso de la fuerza de regularización $C \in \{0.1, 1, 10\}$ bajo un criterio de optimización de convergencia liblinear.
- **K-Nearest Neighbors (K-NN):** Modelo no paramétrico espacial basado en distancias euclidianas, evaluando el impacto del número de vecinos cercanos $k \in \{5, 10, 15\}$ y funciones de ponderación de vecindad (`uniform`, `distance`).
- **Árbol de Decisión (Decision Tree):** Estructura jerárquica no lineal donde se midió la propensión al sobreajuste explorando umbrales de profundidad

máxima (`max_depth` $\in \{5, 10, \text{None}\}$) y muestras mínimas de división (`min_samples_split` $\in \{2, 5\}$).

- **Random Forest (RF):** Arquitectura de ensamble por agregación (Bagging) sugerida por el estado del arte. Se evaluó el número de estimadores de árboles (`n_estimators` $\in \{50, 100\}$) y restricciones en su crecimiento jerárquico (`max_depth` $\in \{5, 10, \text{None}\}$).
- **XGBoost (XGB):** Modelo avanzado de ensamble por optimización de gradiente (Gradient Boosting) enfocado en maximizar la capacidad de discriminación. Se parametrizó la tasa de aprendizaje (`learning_rate` $\in \{0.01, 0.1\}$), la cantidad de árboles (`n_estimators` $\in \{50, 100\}$) y la profundidad de los estimadores base (`max_depth` $\in \{3, 5, 7\}$).

Criterios de Selección Epidemiológica

La grilla de optimización interna se ejecutó bajo la métrica *balanced_accuracy*, asegurando una evaluación equitativa de la sensibilidad en ambos extremos diagnósticos. No obstante, debido a la naturaleza de salud pública y prevención del proyecto, la métrica crítica prioritaria es el *Recall* (Sensibilidad). En la detección temprana de anemia infantil, el costo ético y social de un falso negativo es sumamente crítico, ya que clasificar de forma errónea a un niño enfermo como sano lo excluye de tratamientos oportunos; por ende, se prioriza maximizar el Recall de manera conjunta con la exactitud global (Accuracy) y el Área Bajo la Curva (AUC-ROC).

Resultados y Discusión

Fase de Optimización y Parámetros en Entrenamiento

La ejecución del muestreo en grilla exhaustivo convergió con éxito para los cinco modelos implementados. Conforme a las directrices de la cátedra, la Tabla 3 consolida los hiperparámetros óptimos seleccionados mediante validación cruzada y los tiempos precisos de simulación computacional demandados durante la exploración de la grilla.

Tabla 3


Hiperparámetros óptimos y tiempos de ejecución (GridSearchCV).

Método	Hiperparámetros Probados	Hiperparámetros Óptimos
LogReg	$C: \{0.1, 1, 10\}$ <code>max_iter: {500, 1000}</code>	<code>{'C': 10, 'max_iter': 500}</code>
K-NN	<code>n_neighbors: {5, 10, 15}</code>	<code>{'n_neighbors': 5, 'weights':</code>

	weights: {'uniform', 'distance'}	'distance'}
Decision Tree	max_depth: {5, 10, None} min_samples_split: {2, 5}	{'max_depth': 10, 'min_samples_split': 2}
Random Forest	max_depth: {5, 10, None} n_estimators: {50, 100}	{'max_depth': None, 'n_estimators': 50}
XGBoost	learning_rate: {0.01, 0.1} max_depth: {3, 5, 7} n_estimators: {50, 100}	{'learning_rate': 0.1, 'max_depth': 7, 'n_estimators': 100}

La varianza y estabilidad del desempeño de cada algoritmo durante las 10 iteraciones de la validación cruzada se visualizan en la Figura 1.

Figura 1
Dispersión del desempeño (Balanced Accuracy) en Validación Cruzada (10-Fold CV).



Se evidencia que Random Forest alcanza la mediana de exactitud balanceada más elevada durante la fase de optimización, seguido de cerca por XGBoost y K-NN, superando los tres la barrera del 70% de rendimiento sobre los datos balanceados con SMOTE. Asimismo, el gráfico revela que K-NN exhibe la dispersión más estrecha (caja de menor amplitud), lo que indica una alta estabilidad frente a las perturbaciones del remuestreo, mientras que la Regresión Logística y el Árbol de Decisión presentan una mayor varianza predictiva y la presencia de valores atípicos.

Evaluación en el Conjunto de Prueba

Tras congelar las configuraciones óptimas deducidas de la grilla, los clasificadores se evaluaron por primera y única vez en el conjunto de prueba aislado (30%), generando una confrontación empírica directa que se detalla en la Tabla 4.

Tabla 4

Desempeño de los modelos optimizados en el conjunto de prueba.

Método	Accuracy	Recall	AUC-ROC	Tiempo
LogReg	0.6529	0.6429	0.7092	10.40 s
K-NN	0.5843	0.5931	0.6181	9.16 s
Decision Tree	0.6346	0.5515	0.6425	9.98 s
Random Forest	0.6658	0.4742	0.6753	68.38 s
XGBoost	0.6730	0.4678	0.6843	73.86 s

Discusión y Análisis de Criterios Experimentales

El análisis de las métricas obtenidas (Tabla 4) evidencia lo siguiente:

- **Resolución del Problema:** Todos los modelos evaluados superaron el umbral de clasificación aleatoria ($AUC > 0.50$), lo que demuestra empíricamente la viabilidad de predecir el riesgo temprano de anemia infantil utilizando exclusivamente datos no invasivos (antropométricos, sociodemográficos y de vivienda) provistos por la ENDES 2023, eliminando la dependencia de pruebas de sangre.
- **Eficiencia Computacional:** Se evidenció una alta eficiencia durante la simulación. Las arquitecturas lineales, espaciales y jerárquicas simples (LogReg, K-NN, Decision Tree) se optimizaron en umbrales sumamente bajos (entre 9.16 y 10.4 segundos). En contraposición, los ensambles complejos (Random Forest y XGBoost) demandaron tiempos ligeramente superiores (68.38 y 73.86 segundos, respectivamente). Este coste temporal se gestionó mediante procesamiento paralelo ($n_jobs=-1$), confirmando que la solución es escalable y viable sin requerir infraestructura de cómputo de alta gama.
- **Desempeño Algorítmico Comparado:** Los resultados (Tabla 4) evidencian un compromiso clínico estructural fundamental (trade-off predictivo). El modelo avanzado XGBoost alcanzó la mayor exactitud global de clasificación en prueba (Accuracy: 0.6730), resultado que alcanza exitosamente el baseline establecido por la literatura (Khan et al., 2019; 68.53%) para datos de encuestas demográficas análogas. Cabe destacar que, si bien Random Forest registró una mediana interna superior en validación

cruzada (Figura 1) debido a la simetría artificial inducida por SMOTE en el entrenamiento, XGBoost demostró una mayor capacidad de generalización al enfrentarse a la distribución desbalanceada real del conjunto de prueba. No obstante, bajo la óptica de tamizaje en salud pública, el modelo de Regresión Logística superó a los ensambles en la métrica prioritaria: el Recall (0.6429), registrando en paralelo la mayor capacidad de generalización global de casos con un AUC de 0.7092.

- **Influencia de Parámetros en el Sistema:** El ajuste mediante la grilla exhaustiva demostró que la restricción de crecimiento jerárquico fue indispensable para contrarrestar el sobreajuste inducido por el remuestreo sintético (SMOTE). Para consolidar su exactitud global sin memorizar ruido, XGBoost requirió fijar una tasa de aprendizaje moderada (`learning_rate`: 0.1) combinada con un límite estricto de profundidad (`max_depth`: 7). En sentido inverso, al flexibilizar la frontera de decisión de la Regresión Logística mediante un inverso de regularización elevado (`C`: 10), el algoritmo lineal base maximizó su sensibilidad probabilística, disminuyendo drásticamente los falsos negativos para asegurar la identificación de la mayor proporción posible de infantes vulnerables.

5. Conclusión

La presente investigación validó afirmativamente la hipótesis planteada, demostrando que es metodológicamente viable y útil aplicar modelos de aprendizaje automático para predecir el riesgo temprano de anemia infantil en el Perú (niños de 6 a 59 meses) empleando exclusivamente variables sociodemográficas, antropométricas y habitacionales de la ENDES 2023, prescindiendo de pruebas sanguíneas.

A partir de los resultados empíricos consolidados en el conjunto de prueba, se desprenden las siguientes conclusiones:

- **Validación frente al Estado del Arte:** El ensamble avanzado XGBoost se consolidó como el mejor modelo de discriminación global al alcanzar la mayor exactitud del estudio (`Accuracy`: 0.6730). Este rendimiento supera al modelo probabilístico lineal (0.6529) y alcanza exitosamente el baseline internacional establecido por Khan et al. (2019; 68.53%) para predicciones basadas en encuestas demográficas.
- **Compromiso Clínico para Salud Pública:** Se determinó un compromiso fundamental entre la exactitud global y la sensibilidad epidemiológica. Mientras que los ensambles basados en árboles optimizan la precisión general, el modelo de Regresión Logística resulta superior para fines de tamizaje y prevención al dominar la métrica crítica de Recall (0.6429) y registrar la mayor capacidad de generalización (`AUC`: 0.7092). Al minimizar los falsos negativos, este enfoque garantiza identificar a la mayor proporción de infantes vulnerables.
- **Identificación de Factores de Riesgo:** El análisis del modelado confirmó que los factores antropométricos (talla, peso, puntajes Z), combinados de forma estructural con vulnerabilidades socioeconómicas (índice de riqueza) y brechas de infraestructura habitacional, constituyen indicadores con un alto poder predictivo sobre la enfermedad, lo que responde al objetivo de identificar las variables de mayor influencia en la infancia peruana sin recurrir a datos clínicos.
- **Eficiencia y Viabilidad Tecnológica:** El proceso automatizado de entrenamiento y sintonización demostró ser altamente eficiente, demandando tiempos de simulación sumamente bajos (entre 9 y 75 segundos). Esto dota al Estado de un método escalable, económico y oportuno para focalizar recursos y diseñar políticas de salud pública preventivas descentralizadas antes de que los cuadros clínicos se vuelvan severos.

6. Sugerencias de trabajos futuros

A partir de los resultados obtenidos y las limitaciones identificadas, se proponen las siguientes directrices para futuras investigaciones:

Optimización y Mejoras al Enfoque Predictivo

- **Aprendizaje Sensible al Costo (Cost-Sensitive Learning):** Dado que XGBoost exhibió la mayor exactitud global pero una baja sensibilidad (`Recall`: 0.4678), se propone integrar matrices de costo asimétricas para penalizar con mayor severidad los falsos negativos durante el entrenamiento.
- **Lógica Difusa:** Para abordar la ambigüedad inherente a variables cualitativas (como la precariedad de la vivienda), se sugiere diseñar un Sistema de Inferencia Difusa (FIS) que flexibilice las fronteras rígidas de los clasificadores binarios.
- **Redes Neuronales:** Implementar arquitecturas de aprendizaje profundo (ej.

Perceptrón Multicapa) para evaluar si una extracción no lineal de características supera la capacidad de generalización de los ensambles basados en árboles.

- **Sub-modelos Geográficos:** Basado en el impacto demográfico evidenciado por la Regresión Logística, se recomienda estructurar predictores independientes por regiones naturales (Costa, Sierra y Selva) para mitigar las disparidades estructurales del país.
- **Enriquecimiento de Variables:** Incorporar datos complementarios de la ENDES, como la adherencia a suplementos de hierro y el estado de salud materno durante la gestación.

Extensión a Otros Problemas de Salud Pública

- **Predicción de Desnutrición Crónica Infantil:** El pipeline de procesamiento de datos posee un alto potencial de transferencia. Se propone reutilizar la arquitectura y los indicadores antropométricos (puntajes Z de talla y peso) para la predicción temprana de cuadros de desnutrición crónica y aguda en la primera infancia.

7. Implicancias éticas

El escalamiento poblacional de este sistema predictivo en el sector de la salud pública exige una rigurosa auditoría ética y la implementación de mecanismos de mitigación frente a tres riesgos fundamentales:

Identificación de Riesgos

- **Sesgo Algorítmico y Estigmatización:** El modelo depende fuertemente de variables de vulnerabilidad socioeconómica y de infraestructura (como índice de riqueza o región de residencia). Un escalamiento sin supervisión corre el riesgo de automatizar desigualdades históricas, transformando carencias materiales en un criterio de estigmatización de comunidades vulnerables.
- **Privacidad y Ciberseguridad:** La centralización de registros sociodemográficos y biométricos de menores de edad incrementa la superficie de ataque. Una brecha de seguridad informática implicaría el robo y la exposición masiva de datos altamente confidenciales.
- **Responsabilidad Clínica:** En el tamizaje de salud pública, un falso negativo catalogaría a un menor en riesgo como "sano", impidiendo su tratamiento oportuno. Asimismo, la opacidad de los ensambles

complejos (efecto "caja negra" de XGBoost) limita la interpretabilidad directa por parte del personal médico.

Estrategias de Mitigación

- **Gobernanza y Anonimización:** El tratamiento de la información debe someterse a protocolos de anonimización irreversible y cifrado robusto, garantizando el cumplimiento estricto de la Ley de Protección de Datos Personales (Ley N° 29733).
- **Auditoría e Interpretabilidad (XAI):** Es mandatorio acoplar herramientas de explicabilidad agnóstica (como valores SHAP) para desglosar matemáticamente la contribución de cada variable, dotando al médico de un sustento transparente antes de validar predicciones de modelos complejos.
- **Uso Exclusivo como Tamizaje:** Protocolizar legalmente que el algoritmo actúe única y exclusivamente como un sistema preventivo de alerta temprana. Para ello, se debe priorizar el uso de clasificadores orientados a maximizar la sensibilidad (Regresión Logística, Recall: 0.6429), asegurando que el dictamen algorítmico nunca sustituya la evaluación clínica presencial ni la prueba de hemoglobina.

8. Link del repositorio del trabajo

Link repositorio de GitHub:

<https://github.com/alvarofabrizio/Prediccion-Anemia-Infantil-Peru.git>

9. Declaración de contribución de cada integrante

- **A. López:** Redacción de la introducción y el resumen del artículo, y diseño de la presentación para la sustentación oral.
- **K. Vega:** Revisión del estado del arte y articulación del marco teórico con la experimentación.
- **M. Vásquez:** Procesamiento e integración del dataset base de la ENDES, co-desarrollo metodológico y redacción de las conclusiones.
- **A. Ferro:** Liderazgo en la implementación computacional en Python (Google Colab), ejecución de la fase experimental y soporte metodológico.

Todos los autores revisaron, discutieron los resultados y aprobaron la versión final del presente documento.

10. Declaración de uso de IA

Durante el desarrollo de este proyecto, se empleó el asistente de inteligencia artificial Gemini (de Google). Su uso tuvo como propósito principal asistir en la construcción y optimización de la sintaxis del código en el entorno de Google Colab (implementación de pipelines, preprocesamiento y ajuste algorítmico), así como brindar sugerencias estructurales para la interpretación y redacción técnica de las métricas de evaluación generadas. No obstante, todas las sugerencias analíticas y de redacción de la IA fueron evaluadas y validadas por los autores, asegurando la consistencia de los datos experimentales y asumiendo la responsabilidad total de este informe.

11. Referencias

- [1]. Dhakal, P., Khanal, S. y Bista, R. (2023). Prediction of anemia using machine learning algorithms. International Journal of Computer Science & Information Technology (IJCSIT), 15(1). <https://www.researchgate.net/profile/Rabin-dra-Bista/publication/368845592>
- [2]. Instituto Nacional de Estadística e Informática [INEI]. (2023). Encuesta Demográfica y de Salud Familiar (ENDES). <https://proyectos.inei.gob.pe/microdatos/index.htm>
- [3]. Ja'afar, I. K. y Uthman, O. A. (2025). Predicting childhood anemia in Nigeria: A machine learning approach to uncover key risk factors. Public Health Challenges. <https://onlinelibrary.wiley.com/doi/full/10.1002/puh2.70135>
- [4]. Khan, J. R., Chowdhury, S., Islam, H. y Raheem, E. (2019). Machine learning algorithms to predict the childhood anemia in Bangladesh. Journal of Data Science, 17(1), 195-218. <https://www.researchgate.net/profile/Jahidur-Rahman-Khan/publication/328368657>
- [5]. López, A., Vásquez, M., Vega, K. y Ferro, A. (2026). Dataset consolidado de anemia en el Perú - 2023 [Conjunto de datos no publicado]. Archivo de Google Drive. https://drive.google.com/file/d/1Ztky9Zq8ltPxROuHiSJttEGriWx82rH9/view?usp=drive_link