




PUCP


MODELO DE APRENDIZAJE AUTOMÁTICO PARA LA DETECCIÓN TEMPRANA DE ANEMIA INFANTIL EN EL PERÚ

Presentado por

Adrianna Angelyna López Mejía
Martin Smith Vásquez Cainicela
Kevin Stive Vega Rivera
Alvaro Fabrizio Ferro Domínguez

INTELIGENCIA ARTIFICIAL





EL PROBLEMA

- Diagnóstico actual reactivo e invasivo.
- Dependencia absoluta de pruebas de sangre (hemoglobina).
- Limitada capacidad de prevención a nivel nacional.

LA SOLUCIÓN

Enfoque preventivo usando IA con factores de riesgo sociales.




OBJETIVO CENTRAL

Predecir tempranamente el riesgo en niños (6 a 59 meses) usando encuestas demográficas.

ESTADO DEL ARTE

Países Investigados	Autor - Año	Algoritmo mejor desempeño	Variables Relevantes
Anemia en Nepal	Dhakal et al. (2023)	Random Forest con precisión: 98.4%.	Nivel hemoglobina, glóbulos rojos, volumen corpuscular.
Anemia en Bangladesh	Khan et al. (2019)	Random Forest con precisión: 68.53%	Edad, peso y talla del niño; y nivel de riqueza y educativo del hogar.
Anemia en Nigeria	Ja'afar y Uthman (2025)	Extra Trees con precisión: 75.65%	Sexo del niño, distancia a fuentes de agua, ubicación geografica y condiciones del suelo.
Países Investigados	Autor - Año	Algoritmo mejor desempeño	Variables Relevantes




● METODOLOGÍA - CONSTRUCCIÓN DEL DATASET

BLOQUE 1: ORIGEN DE LOS DATOS




ENDES 2023 (INEI)

Fusión de 3 Módulos:
Vivienda, Hogar y
Peso-Talla/Anemia




BLOQUE 2: PROCESAMIENTO Y LIMPIEZA



Integración y Preprocesamiento

- Cruce de registros por ID único
- Limpieza y validación


BLOQUE 3: RIGOR METODOLÓGICO



Prevención de Fuga de Datos

Exclusión definitiva de
la variable
"Hemoglobina"

BLOQUE 4: EL DATASET FINAL LISTO PARA EL MODELO




Dataset Final

- 16 Variables Predictoras + 1 Target Binario (**Anemia**).
- N = 16035 registros finales

SETUP EXPERIMENTAL

Método	Hiperparámetros Probados	Hiperparámetros Óptimos
LogReg	C: {0.1, 1, 10} max_iter: {500, 1000}	{'C': 10, 'max_iter': 500}
K-NN	n_neighbors: {5, 10, 15} weights: {'uniform', 'distance'}	{'n_neighbors': 5, 'weights': 'distance'}
Decision Tree	max_depth: {5, 10, None} min_samples_split: {2, 5}	{'max_depth': 10, 'min_samples_split': 2}
Random Forest	max_depth: {5, 10, None} n_estimators: {50, 100}	{'max_depth': None, 'n_estimators': 50}
XGBoost	learning_rate: {0.01, 0.1} max_depth: {3, 5, 7} n_estimators: {50, 100}	{'learning_rate': 0.1, 'max_depth': 7, 'n_estimators': 100}



**Validación Cruzada
Estratificada (10-Fold CV)**


**Mitigación de desbalance
con SMOTE (solo en Train)**



EVALUACIÓN FINAL

Método	Accuracy	Recall	AUC-ROC	Tiempo
LogReg	0.6529	0.6429	0.7092	10.40 s
K-NN	0.5843	0.5931	0.6181	9.16 s
Decision Tree	0.6346	0.5515	0.6425	9.98 s
Random Forest	0.6658	0.4742	0.6753	68.38 s
XGBoost	0.6730	0.4678	0.6843	73.86 s

DISCUSIÓN - EL TRADE-OFF CLÍNICO




PRECISIÓN VS. PREVENCIÓN




Su arquitectura captura relaciones no lineales complejas que modelos base (como KNN) no ven.

XGBoost





Gana en discriminación global (**Accuracy**). Iguala el estándar de la literatura.


LogReg



Gana en sensibilidad (**Recall**). Minimiza falsos negativos: ideal éticamente para tamizaje en salud pública.




CONCLUSIÓN



HIPÓTESIS VALIDADA

Se demostró con datos de la ENDES que es posible tamizar el riesgo de anemia sin depender de pruebas invasivas ni clínicas.




SOLUCIÓN EFICIENTE

Un sistema escalable, económico y de bajo costo computacional (entrenamiento en menos de 2 minutos). Viable para implementarse a nivel nacional.




EL ROL DE LA IA



Funciona como una potente herramienta de alerta temprana complementaria. Permite focalizar recursos, no es un reemplazo del diagnóstico clínico.







**THANK
YOU!**



ESTABILIDAD EN VALIDACIÓN CRUZADA



TRATAMIENTO DE MULTICOLINEALIDAD



TRABAJOS FUTUROS Y OPTIMIZACIONES

Bloque 1: Aprendizaje Sensible al Costo (Cost-Sensitive Learning)

- Objetivo: Solucionar el bajo Recall de XGBoost (0.4678).
- Acción técnica: Integrar matrices de costo asimétricas en la función de pérdida.
- Impacto: Penalizar matemáticamente y con mayor severidad los Falsos Negativos durante el entrenamiento.

Bloque 2: Redes Neuronales (Deep Learning)

- Objetivo: Superar el límite de los ensambles (Árboles).
- Acción técnica: Implementar arquitecturas conexionistas como el Perceptrón Multicapa (MLP).
- Impacto: Lograr una extracción profunda de características no lineales más complejas.

Bloque 3: Lógica Difusa y Sub-modelos Geográficos

- Objetivo: Manejar la ambigüedad de encuestas y las disparidades del Perú.
- Acción técnica:
 - Crear Sistemas de Inferencia Difusa (FIS) para variables cualitativas (ej. precariedad de vivienda).
 - Entrenar modelos independientes por región (Costa, Sierra y Selva).

**THANK
YOU X2!**

